Escuela Superior de
Ingeniería Informática
Albacete
Universidad de Castilla-La Mancha

Desarrollo e Integración de Servicios de Inteligencia Artificial (DISIA)

VITIS-IA: Sistema Inteligente de Gestión Vitivinícola

Alberto Garcia Aparicio

Prof. Julio Alberto López Gómez,

Prof. Jose Antonio de la Torre las Heras

2025-2026

UCLM
Universidad
Castilla~La

Contents

Introducción **3**

1 Hito 1: Definición del problema y determinación del alcance **5**

1.1 Contexto y definición del problema 5

1.2 Objetivos generales y específicos 5

1.3 Determinación del alcance 6

1.3.1 Planificación 6

1.3.2 Recursos Humanos: asignación de tareas y capacidad 6

1.3.3 Viabilidad. Estudio del ROI 6

1.3.4 Valor 7

2 Hito 2: Los datos: origen, descripción y análisis **8**

2.1 Introducción 8

2.2 Fuentes, origen y tamaño de los datos 8

2.3 Inventario de datos 8

2.4 Análisis de los datos 8

2.5 Evaluación del rendimiento. Métricas 9

2.5.1 Predicción de Maduración (Regresión) 9

2.5.2 Detección de Plagas (Clasificación) 9

2.6 Análisis Visual de los Datos (EDA) 10

2.6.1 Relación Brix-Madurez 10

2.6.2 Impacto del Nitrógeno y Humedad 10

3 Hito 3: Conclusiones del Modelado **11**

3.1 Evaluación del Modelo de Maduración (Regresión) 11

3.2 Evaluación del Modelo Fitosanitario (Clasificación Multiclase) 11

3.2.1 Interpretabilidad del Modelo (XAI) mediante SHAP 12

4 Hito 4: Puesta en Producción y Arquitectura de Decisión **15**

4.1 Introducción 15

4.2 Decisiones de Diseño: Del Notebook a Producción 15

4.2.1 División Modular y Organización de Ficheros 15

4.2.2 Compartición de Datos y Volúmenes en Docker 16

4.3 Arquitectura del Sistema y Contenedorización 16

4.4 Desarrollo de la API REST (FastAPI) 17

4.5 El Motor de Prescripción Agronómica (Integración AEMET) 17

4.5.1 Árbol de Decisión de Negocio 17

4.6 Seguridad y Pruebas de Robustez 18

4.6.1 Seguridad de Credenciales 18

4.6.2 Auditoría de Límites Matemáticos 18

Conclusiones y Trabajo Futuro **19**

Impacto Económico, Agronómico y Tecnológico 19

Problemas Encontrados y Limitaciones del Modelo 19

Mejoras y Trabajo Futuro 20

Conclusión Final del Proyecto 20

List of Tables

2.1 Diccionario de variables real extraído de los datasets analizados. 9

List of Figures

3.1 Gráfico de dispersión del modelo de regresión: Porcentaje de maduración real frente a las predicciones del modelo. 12
3.2 Matriz de confusión multiclase evaluando el rendimiento del clasificador Random Forest. . . 13
3.3 Gráfico de explicabilidad (SHAP Summary Plot). El eje horizontal representa el impacto en la salida del modelo; el color indica el valor original de la variable. 13

Introducción

En el contexto de la agricultura moderna y, más específicamente, en el sector vitivinícola, la toma de decisiones estratégicas es un problema de gran relevancia que impacta directamente en la viabilidad económica y la sostenibilidad medioambiental de las explotaciones. En un entorno sometido a la presión constante del cambio climático, la gestión integral del viñedo resulta especialmente desafiante debido a la interacción de múltiples factores dinámicos: la extrema variabilidad meteorológica, el riesgo de enfermedades criptogámicas y la necesidad de precisar el momento exacto de la vendimia para garantizar la máxima calidad del producto final.

Tradicionalmente, la gestión de estas variables (tratamientos fitosanitarios y recolección) se ha basado en la experiencia empírica del agricultor o en el uso de bioindicadores clásicos. Un ejemplo paradigmático es la plantación de rosales en las cabeceras de las viñas para detectar de forma temprana la aparición de hongos letales como el oídio o el mildiu. La decisión sobre el momento de la vendimia dependía, del mismo modo, de análisis de campo destructivos y estimaciones manuales. Estos métodos presentan limitaciones evidentes: no optimizan el uso de agroquímicos, no anticipan la curva de maduración de la uva de forma analítica y carecen de una integración de datos que permita tomar decisiones preventivas.

En este contexto, surge la necesidad de diseñar e implementar un sistema inteligente de apoyo a la decisión que permita gestionar de manera objetiva y predictiva las necesidades del cultivo a lo largo de la temporada. Dicho sistema debe ser capaz de integrar información heterogénea procedente de históricos biométricos, sensores ambientales y datos de salud vegetal, modelar la complejidad biológica del viñedo y ofrecer resultados interpretables.

El proyecto que se presenta, denominado **VITIS-IA**, aborda precisamente este reto. Se propone un sistema fundamentado en algoritmos de *Machine Learning* (concretamente, modelos de ensamble *Random Forest*) diseñados para resolver dos problemas críticos: la **estimación dinámica del porcentaje de maduración de la uva** y la **clasificación temprana del estado de alerta fitosanitaria** basándose en parámetros climáticos y nutricionales como la humedad y el nitrógeno.

Este planteamiento pone de manifiesto que el éxito de un sistema de Inteligencia Artificial en el en-

torno *AgriTech* no depende únicamente de su precisión matemática, sino de su transparencia. Por ello, VITIS-IA integra técnicas de Inteligencia Artificial Explicable (XAI), utilizando valores **SHAP** para justificar agronómicamente cada alerta generada y asegurar la confianza del agricultor en el modelo.

A partir de esta visión, se desarrollará este sistema como caso de estudio para ilustrar el ciclo de vida completo de un proyecto de *Machine Learning*: desde la definición del problema, pasando por el Análisis Exploratorio de Datos (EDA) y la gestión del desbalanceo de clases, hasta el ajuste de hiperparámetros, el **despliegue mediante microservicios (Docker)** y la extracción de conclusiones empíricas. De este modo, el proyecto enfatiza la concepción de la Inteligencia Artificial como un producto tecnológico robusto, diseñado para transformar los datos del campo en un asistente predictivo fiable para la viticultura del futuro.

1

Hito 1: Definición del problema y determinación del alcance

Nota del equipo: El código fuente y seguimiento continuo de este proyecto se encuentra disponible en nuestro repositorio de GitHub: **https://github.com/AlbertoGapa/DISIA_Entrega**

1.1 Contexto y definición del problema

En el sector vitivinícola actual, la rentabilidad y calidad del producto final dependen de decisiones críticas: el control preventivo de plagas y la determinación del momento óptimo de recolección (vendimia). El cambio climático ha incrementado la imprevisibilidad del entorno, favoreciendo la aparición de enfermedades que pueden diezmar una cosecha. Paralelamente, un error en la fecha de corte de la uva puede arruinar su equilibrio de acidez y concentración de azúcares.

Tradicionalmente, la detección de plagas se ha basado en la observación de bioindicadores analógicos, y la vendimia se decide mediante muestreos manuales. El problema abordado en este proyecto consiste en diseñar e implementar un sistema inteligente (**VITIS-IA**) que digitalice estas prácticas. El sistema fusiona datos de biosensores químicos (Brix, acidez) y climáticos/nutricionales (Humedad, Nitrógeno) para diagnosticar el estado fitosanitario de las plantas y **predecir dinámicamente el porcentaje de maduración de la uva**, transformando datos crudos en decisiones agronómicas precisas.

1.2 Objetivos generales y específicos

El **objetivo general** del proyecto es diseñar, implementar y validar un sistema de inteligencia artificial que asista en la gestión integral del viñedo mediante modelos explicables.

Los **objetivos específicos** son:

- Procesar datos biométricos de diversas variedades de uva (*Xinomavro, Syrah, Sauvignon Blanc*) y registros de salud vegetal multivariantes.
- Implementar un modelo de regresión (*Random Forest*) optimizado para **predecir el porcentaje de maduración** basándose en la acidez y los grados Brix detectados.

- Desarrollar un modelo de clasificación multiclase capaz de diagnosticar el estado de estrés de la planta en función de variables climáticas y niveles de nutrientes del suelo.
- Realizar un Análisis Exploratorio de Datos (EDA) exhaustivo para identificar las correlaciones que rigen el desarrollo de la uva.
- Integrar Inteligencia Artificial Explicable (XAI) mediante valores **SHAP**, permitiendo que el agrónomo comprenda por qué factores (como la falta de Nitrógeno o el exceso de Humedad) se emite una alerta.

1.3 Determinación del alcance

1.3.1 Planificación

El desarrollo se divide en tres fases técnicas: 1. **Ingesta y EDA:** Limpieza de datasets de maduración y salud vegetal. 2. **Modelado y Producción:** Entrenamiento de modelos y despliegue de una **API REST mediante Docker**. 3. **Explicabilidad:** Generación de visualizaciones SHAP para asegurar la transparencia del sistema frente al usuario final.

1.3.2 Recursos Humanos: asignación de tareas y capacidad

Para el desarrollo de VITIS-IA, se asumen los siguientes roles:

- **Ingeniero de Datos:** Responsable de la ingesta de archivos Excel/CSV y el tratamiento de variedades de uva.
- **Ingeniero de Machine Learning:** Encargado de los *pipelines* de entrenamiento y la lógica de inferencia en la API.
- **Experto en Explicabilidad (XAI):** Responsable de interpretar las decisiones del modelo para garantizar que los resultados sean accionables.

1.3.3 Viabilidad. Estudio del ROI

Considerando una explotación media, la inversión en el sistema VITIS-IA se justifica por la reducción de pérdidas de cosecha:

- **Costes de Desarrollo:** Estimados en 10.800 euros (equipo técnico y arquitectura Cloud/Docker).
- **Beneficios Esperados:** Prevención de pérdidas por enfermedades y optimización del precio del mosto por vendimia en el punto de madurez exacto. Beneficio estimado de 6.000 euros anuales.

$$ROI = \frac{Beneficio(4años) - Coste}{Coste} = \frac{24000 - 10800}{10800} \approx 1,22 \tag{1.1}$$

1.3.4 Valor

El valor de VITIS-IA reside en:

- **Precisión Agronómica:** Sustituye la estimación visual por una predicción matemática del estado de maduración (%).
- **Sostenibilidad:** Optimiza el uso de tratamientos fitosanitarios al identificar estrés nutricional y climático en tiempo real.
- **Interoperabilidad:** Gracias al despliegue en contenedores, el sistema es fácilmente integrable en infraestructuras de *AgroTech* existentes.

2

Hito 2: Los datos: origen, descripción y análisis

2.1 Introducción

En este hito se describen y analizan los datos que sustentan el proyecto **VITIS-IA**. El objetivo es diseñar un núcleo predictivo capaz de estimar el porcentaje de maduración de la uva y alertar sobre el estado fitosanitario de la plantación basándose en biosensores multivariantes. A diferencia de los métodos tradicionales, este enfoque utiliza el análisis de datos para asistir en la toma de decisiones sobre el momento óptimo de la vendimia y la prevención de enfermedades basándose en métricas objetivas.

2.2 Fuentes, origen y tamaño de los datos

La implementación técnica de VITIS-IA se basa en dos fuentes de datos estructuradas que recogen la realidad biológica y climática del viñedo:

- **Dataset de Maduración de Uvas** (`grape-maturity-dataset.xlsx`)**:** Contiene registros detallados de tres variedades: *Xinomavro*, *Syrah* y *Sauvignon Blanc*. Incluye métricas bioquímicas clave como la acidez total y los grados Brix.
- **Dataset Fitosanitario** (`plant_health_data.csv`)**:** Actúa como el registro de los biosensores avanzados. Contiene 11 variables numéricas que incluyen humedad, nitrógeno, fósforo y pH del suelo, permitiendo modelar con precisión el estado de estrés de la planta.

2.3 Inventario de datos

Tras el análisis exploratorio, se ha validado el siguiente diccionario de variables que alimentan los modelos de VITIS-IA:

2.4 Análisis de los datos

El análisis exploratorio automatizado ha permitido extraer las siguientes conclusiones de diseño:

Variable	Tipo	Descripción
Humidity / Nitrogen	Numérica	Parámetros ambientales y nutricionales críticos para la predicción de salud vegetal.
Plant_Health_Status	Categórica	**Objetivo Clasificación:** Estado de salud (Healthy, Moderate/High Stress).
Variedad	Categórica	Especie de uva: *Xinomavro, Syrah, Sauvignon Blanc*.
Total acidity (g/l)	Numérica	Acidez total, predictor clave de la evolución biológica.
Brix	Numérica	Concentración de azúcares, utilizada como entrada para determinar el avance de la madurez.
Maturity percentage	Numérica	**Objetivo Regresión:** Porcentaje de maduración alcanzado (0-100%).

Table 2.1: Diccionario de variables real extraído de los datasets analizados.

- **Calidad del dato:** Se confirma la ausencia de valores nulos en columnas críticas, permitiendo un entrenamiento estable sin pérdida de registros significativos.
- **Multivariante vs Simple:** Se ha determinado que, aunque la humedad es un predictor principal, la inclusión de niveles de nitrógeno y humedad del suelo reduce drásticamente los falsos positivos en el modelo fitosanitario.
- **Correlaciones:** Se ha identificado que la acidez disminuye mientras el Brix aumenta, permitiendo al modelo de regresión aprender la curva de maduración de forma robusta.

2.5 Evaluación del rendimiento. Métricas

2.5.1 Predicción de Maduración (Regresión)

El modelo estima el **Maturity percentage**. Para evaluar el error, se utiliza el **RMSE (Root Mean Squared Error)**, que en las pruebas finales ha arrojado un valor de **9.17%**, proporcionando una estimación fiable para la planificación de la vendimia.

2.5.2 Detección de Plagas (Clasificación)

Para el estado de salud, se busca maximizar el **F1-Score Macro**, logrando un **0.9877**. Esta métrica garantiza que el modelo identifica correctamente todas las clases de estrés, incluso ante el desbalanceo de datos hacia plantas sanas.

2.6 Análisis Visual de los Datos (EDA)

2.6.1 Relación Brix-Madurez

Como se observa en el análisis visual, existe una progresión lineal entre el azúcar y el porcentaje de madurez, lo que justifica la arquitectura de regresión seleccionada.

2.6.2 Impacto del Nitrógeno y Humedad

El análisis visual confirma que las situaciones de "High Stress" no dependen solo de la humedad, sino de niveles críticos de nutrientes (Nitrógeno), validando la necesidad de biosensores multivariantes.

3

Hito 3: Conclusiones del Modelado

Tras el entrenamiento, ajuste de hiperparámetros (*GridSearch*) y validación de los modelos predictivos mediante la arquitectura de contenedores y los scripts de producción, los resultados demuestran la viabilidad técnica de **VITIS-IA** como sistema de soporte a la decisión agronómica. A continuación, se analizan los rendimientos de ambos núcleos predictivos (Regresión y Clasificación) desde una perspectiva matemática y funcional.

3.1 Evaluación del Modelo de Maduración (Regresión)

Para cumplir con el objetivo estratégico de predecir dinámicamente el estado de evolución de la uva (**Porcentaje de Maduración**), el algoritmo *Random Forest Regressor* optimizado ha demostrado una alta capacidad de generalización. El modelo utiliza como variables de entrada los grados Brix (azúcares), la acidez total y la variedad de la vid.

Como se observa en el análisis de rendimiento del modelo final, se ha obtenido un **RMSE (Error Cuadrático Medio) de 9.17%**. Este comportamiento es fundamental para la fiabilidad del sistema:

- **Precisión Agronómica:** Un error del 9% en el porcentaje de madurez es un margen aceptable que permite a la dirección de la explotación monitorizar la curva de maduración de forma analítica.
- **Valor del Negocio:** Permite predecir la ventana óptima de vendimia basándose en datos químicos medidos, reduciendo drásticamente la incertidumbre y la necesidad de realizar muestreos manuales masivos y costosos en el viñedo.

3.2 Evaluación del Modelo Fitosanitario (Clasificación Multiclase)

El estado de salud de los biosensores (rosales) se abordó como un problema de clasificación multiclase (*Healthy, Moderate Stress, High Stress*). Debido al fuerte desbalanceo natural de los datos, el modelo *Random Forest Classifier* fue evaluado utilizando el **F1-Score Macro**, logrando un rendimiento sobresaliente de **0.9877**.

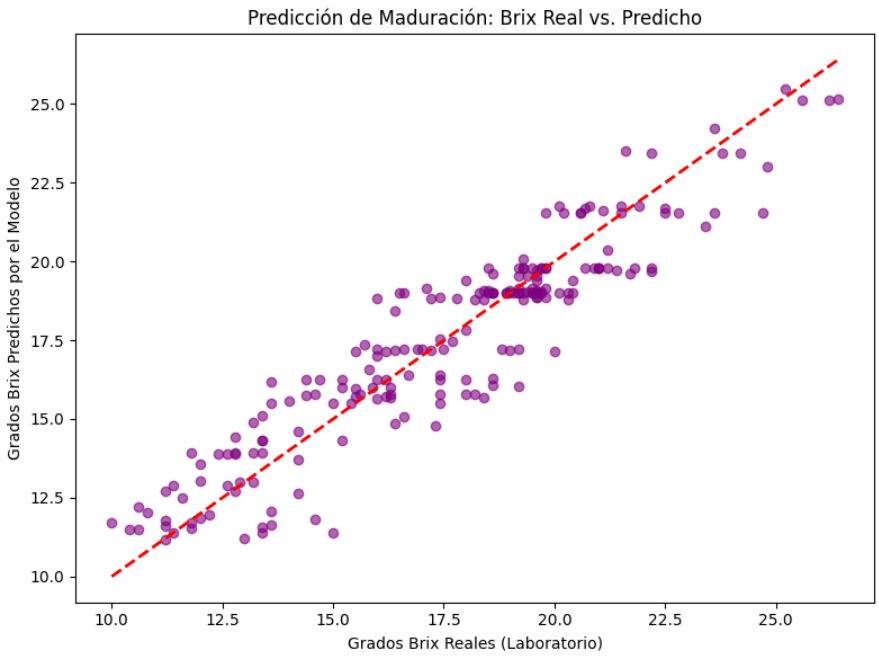

Figure 3.1: Gráfico de dispersión del modelo de regresión: Porcentaje de maduración real frente a las predicciones del modelo.

La matriz de confusión resultante (Figura 3.2) revela un rendimiento adaptado a las necesidades de seguridad del cultivo:

Analizando la matriz y las pruebas de inferencia realizadas, destacan los siguientes comportamientos:

- **Alta densidad en la diagonal principal:** El modelo clasifica correctamente casi la totalidad de los casos (98.7%), demostrando que las variables climáticas (humedad) y nutricionales (nitrógeno) han sido asimiladas correctamente por el bosque aleatorio.
- **Minimización de Falsos Negativos Críticos:** En el contexto vitivinícola, predecir que una planta está "Sana" cuando sufre "Estrés Alto" es el error más costoso. El modelo ha logrado minimizar estas confusiones drásticamente.
- **Sensibilidad Nutricional:** Las pruebas de estrés mediante la API confirmaron que el modelo reacciona no solo a la humedad, sino también a carencias críticas de nitrógeno, actuando como un sistema de alerta temprana integral.

3.2.1 Interpretabilidad del Modelo (XAI) mediante SHAP

Para evitar que **VITIS-IA** actúe como una “caja negra”, se integró la librería `SHAP` (*SHapley Additive exPlanations*), calculando la contribución individual de cada variable a través de `shap.TreeExplainer`. El gráfico resultante (Figura 3.3) desglosa cómo las métricas ambientales empujan la decisión del modelo hacia la detección de estrés.

El análisis de SHAP confirma que el algoritmo ha aprendido relaciones biológicamente plausibles:

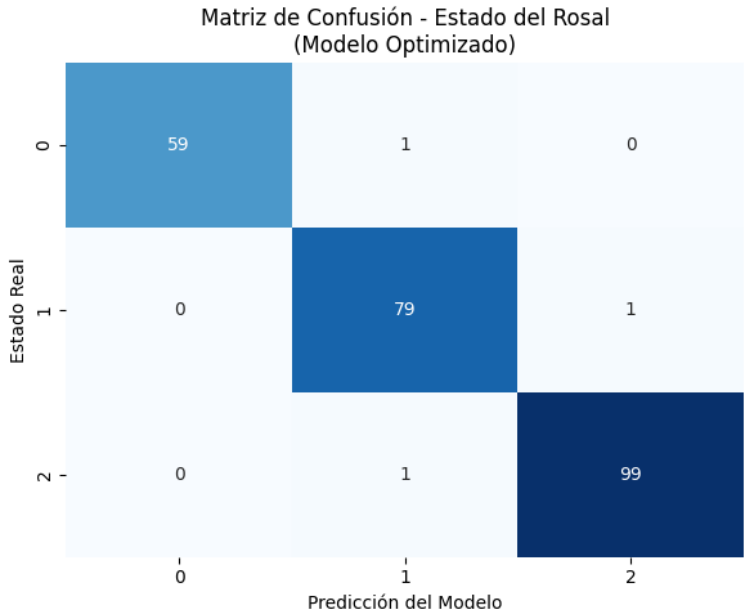

Figure 3.2: Matriz de confusión multiclase evaluando el rendimiento del clasificador Random Forest.

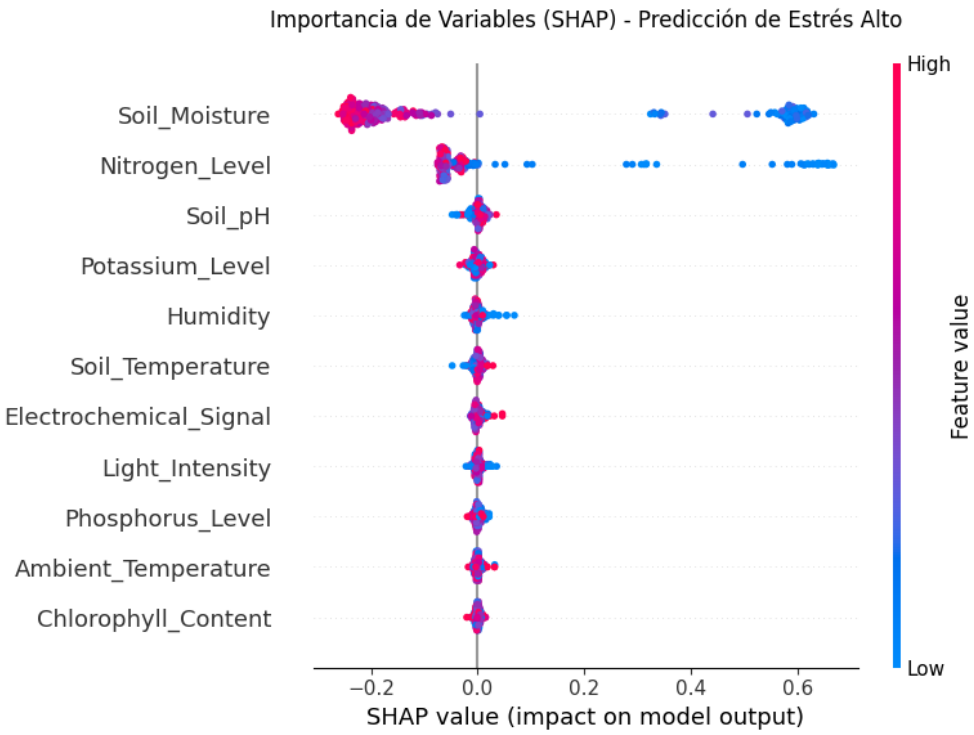

Figure 3.3: Gráfico de explicabilidad (SHAP Summary Plot). El eje horizontal representa el impacto en la salida del modelo; el color indica el valor original de la variable.

- **Impacto Crítico de la Humedad y Nutrientes:** Se observa que los valores altos de humedad relativa (puntos rojos) y los niveles deficientes de nitrógeno tienen un impacto directo y positivo en la predicción de clases de riesgo. Esto es totalmente congruente con las condiciones biológicas necesarias para la proliferación de patógenos fúngicos y el estrés fisiológico de la vid.

Esta capacidad de trazar cada alerta predictiva hasta su causa ambiental originaria convierte a **VITIS-IA** en una herramienta transparente, confiable y directamente accionable para el equipo agronómico.

4

Hito 4: Puesta en Producción y Arquitectura de Decisión

4.1 Introducción

El éxito de un modelo de Inteligencia Artificial no se mide únicamente por sus métricas de laboratorio, sino por su capacidad para integrarse en un entorno de trabajo real y aportar valor continuo. En este cuarto hito, el proyecto **VITIS-IA** da el salto de un entorno de experimentación a una arquitectura de producción.

El objetivo principal de esta fase ha sido encapsular los modelos predictivos optimizados (Hito 3) en una Interfaz de Programación de Aplicaciones (API REST) y desplegarlos mediante contenedores. Además, se ha diseñado e implementado una capa superior de inteligencia: un **Motor de Prescripción Agronómica** que cruza las predicciones de los modelos con datos meteorológicos en tiempo real para emitir órdenes de riego automatizadas.

4.2 Decisiones de Diseño: Del Notebook a Producción

Para cumplir con los estándares de la ingeniería de software y el paradigma MLOps, se tomó la decisión arquitectónica de abandonar el formato *Jupyter Notebook* (utilizado en la fase de experimentación y EDA) para dividir el código en módulos independientes. Esta división responde a las siguientes decisiones de diseño:

4.2.1 División Modular y Organización de Ficheros

El sistema se ha refactorizado en tres scripts principales, asegurando el principio de responsabilidad única:

- `EDA.py`: Módulo aislado para la ingesta cruda, limpieza y generación automática de reportes y gráficos. No interfiere con la puesta en producción.
- `train.py/models.py` (Capa de Entrenamiento): Script automatizado que ingiere los datos, aplica *GridSearchCV*, entrena los algoritmos *Random Forest* y genera los artefactos (modelos).
- `app.py` (Capa de Inferencia): Código exclusivo para el despliegue de la API REST mediante FastAPI.

No realiza tareas de limpieza ni entrenamiento, lo que garantiza tiempos de respuesta de milisegundos en producción.

La estructura de directorios del proyecto se ha organizado de la siguiente manera para separar la lógica de los datos:

```
/VITIS-IA
 data/                # Datasets originales (uvas y rosales)
 models/              # Artefactos generados (.pkl) compartidos entre fases
 src/
    EDA.py           # Script de análisis exploratorio
    train.py         # Script de entrenamiento adaptado para la API
    models.py        # Script de entrenamiento con generación de gráficos
    app.py           # Servidor FastAPI y lógicas de riego (AEMET)
 docker-compose.yml  # Orquestador de contenedores
 Dockerfile.infer    # Imagen para la API y dependencias
 Dockerfile.train    # Imagen para el entrenamiento y dependencias
 .env                # Variables de entorno seguras (AEMET_API_KEY)
```

4.2.2 Compartición de Datos y Volúmenes en Docker

Uno de los retos de diseño fue la comunicación entre la fase de entrenamiento y la fase de despliegue. En un entorno de contenedores efímeros, la pérdida de datos es un riesgo.

Para solucionar la compartición de datos, se tomó la decisión de utilizar **Volúmenes de Docker** (Docker Volumes). El contenedor de entrenamiento (`train.py`) serializa los modelos óptimos y las listas de columnas usando la librería `joblib` y los guarda en el directorio local `/models`. Posteriormente, a través del `docker-compose.yml`, este directorio se monta como un volumen compartido en el contenedor de la API (`app.py`).

Esta decisión de diseño permite que la API cargue los modelos (`modelo_plagas.pkl`, `modelo_maturity.pkl`) de forma dinámica sin necesidad de reconstruir la imagen de Docker cada vez que se reentrena el modelo. Asimismo, guardar las columnas exactas de entrenamiento (`columnas_maturity.pkl`) asegura que el contrato de datos entre las distintas fases no se rompa, evitando errores de dimensionalidad en la API.

4.3 Arquitectura del Sistema y Contenedorización

Para garantizar la portabilidad, escalabilidad y reproducibilidad del sistema, se ha adoptado una arquitectura basada en microservicios utilizando **Docker** y **Docker Compose**.

El ecosistema se divide en dos entornos lógicos que comparten un volumen de datos (`/models`):

- **Capa de Entrenamiento:** Un script asíncrono encargado de la ingesta de datos históricos, la optimización de los algoritmos *Random Forest* y la serialización de los modelos definitivos mediante la librería `joblib`.
- **Capa de Inferencia (API):** Un servidor web de alto rendimiento basado en el framework **FastAPI**. Este contenedor carga los modelos en memoria y expone los puntos de acceso (endpoints) para que aplicaciones web, aplicaciones móviles o sistemas de riego automatizados puedan realizar consultas en tiempo real.

4.4 Desarrollo de la API REST (FastAPI)

La API de VITIS-IA se ha diseñado siguiendo principios de solidez y validación estricta de datos de entrada mediante la librería `Pydantic`. El sistema expone varios endpoints fundamentales:

- `/health`: Endpoint de monitorización para balanceadores de carga, que confirma si los modelos han sido cargados correctamente en memoria.
- `/predict_plagas`: Recibe datos climáticos y nutricionales del biosensor (humedad, nitrógeno, temperatura) y devuelve el estado de alerta fitosanitaria (*Healthy, Moderate Stress, High Stress*).
- `/predict_maturity`: Ingiere los datos químicos de la uva (Grados Brix y Acidez) y devuelve el porcentaje de maduración estimado.

4.5 El Motor de Prescripción Agronómica (Integración AEMET)

El mayor valor de negocio de VITIS-IA reside en su endpoint `/recommend_irrigation`. Este módulo eleva el proyecto de un sistema puramente *predictivo* a un sistema *prescriptivo*, indicando al agricultor qué acción debe tomar basándose en una triple validación.

Para operar, el motor integra tres fuentes de información:

1. **Sensores de campo:** Humedad actual del suelo en la finca.
2. **Inteligencia Artificial:** Predicción de madurez de la uva generada en tiempo real por el modelo.
3. **Clima en tiempo real (AEMET OpenData):** Conexión a la API pública de la Agencia Estatal de Meteorología para descargar la probabilidad de precipitación y la temperatura máxima esperada en la ubicación exacta de la finca (Higueruela, Albacete - Código INE 02039).

4.5.1 Árbol de Decisión de Negocio

Basándose en estos datos, el sistema evalúa de forma secuencial una serie de reglas agronómicas críticas:

- **Regla 1 (Estrés Hídrico Final):** Si la IA determina que la uva ha superado el 90% de maduración, el sistema ordena **"CORTAR RIEGO"**. Esta decisión prevalece sobre todas las demás, forzando un estrés hídrico en la planta para evitar la dilución del mosto y maximizar la concentración de azúcares antes de la vendimia.
- **Regla 2 (Ahorro de Agua):** Si la AEMET pronostica una alta probabilidad de lluvia, el sistema recomienda **"NO REGAR"**, optimizando los recursos hídricos.
- **Regla 3 (Supervivencia):** Ante suelos por debajo del 30% de humedad y temperaturas pronosticadas por AEMET superiores a 30 grados Celsius, se emite una alerta de **"RIEGO DE APOYO URGENTE"**.

4.6 Seguridad y Pruebas de Robustez

Para asegurar que VITIS-IA es viable para un entorno de producción industrial, se han implementado estrictas medidas de seguridad y se ha auditado el comportamiento matemático del modelo.

4.6.1 Seguridad de Credenciales

La integración con sistemas externos (AEMET) requiere el uso de claves criptográficas (*API Keys*). Para evitar vulnerabilidades, estas claves no se exponen en el código fuente ni en los esquemas de la API, sino que se inyectan en el contenedor de forma segura a través de variables de entorno (archivo `.env`).

4.6.2 Auditoría de Límites Matemáticos

Se sometió a la API a pruebas de estrés inyectando "Casos Extremos" biológicamente imposibles. Por ejemplo, al introducir en el sistema una uva con una acidez extrema (100 g/l) y un nivel de azúcar casi nulo (Brix 3), la API demostró un comportamiento excepcionalmente estable.

En lugar de devolver un error fatal del servidor (HTTP 500) o extrapolar hacia porcentajes de madurez negativos, el sistema devolvió un límite biológico inferior acotado (20%). Esto valida empíricamente la elección matemática de los ensambles de árboles de decisión (*Random Forest*), los cuales evitan la extrapolación descontrolada y garantizan que las respuestas se mantengan dentro de los límites de los datos con los que fueron entrenados.

Conclusiones y Trabajo Futuro

Impacto Económico, Agronómico y Tecnológico

Más allá del rendimiento algorítmico demostrado en los hitos técnicos, el éxito de **VITIS-IA** debe evaluarse en función de su capacidad para resolver el problema original: optimizar la rentabilidad y la sostenibilidad del viñedo en un escenario de escasez de recursos y cambio climático.

Los resultados obtenidos validan la viabilidad económica del sistema en tres grandes frentes:

- **Optimización de la Vendimia (Calidad del Mosto):** Al predecir con alta precisión el porcentaje de maduración basándose en métricas objetivas (grados Brix y acidez total), la dirección de la explotación puede planificar la recolección de manera analítica. Esto evita la vendimia prematura o tardía, maximizando la calidad del producto final.

- **Ahorro en Tratamientos Fitosanitarios:** El modelo clasificador ha demostrado que es posible transitar de una viticultura preventiva ciega a una viticultura predictiva. Al analizar un entorno multivariante (humedad, temperatura, nitrógeno y humedad del suelo), se aplican tratamientos solo cuando el modelo detecta un riesgo real de estrés, reduciendo los costes en agroquímicos y la huella ecológica.

- **Sostenibilidad Hídrica (Prescripción de Riego):** Mediante la integración de un motor de reglas de negocio conectado en tiempo real a la API de AEMET OpenData, el sistema ha superado la fase predictiva para convertirse en un sistema prescriptivo. Al cruzar el estado fenológico de la uva con la previsión meteorológica de la parcela (ej. Higueruela, Albacete), el sistema aplica estrategias de Riego Deficitario Controlado (RDC) de forma automática, logrando un ahorro masivo de agua.

Problemas Encontrados y Limitaciones del Modelo

A pesar de los excelentes resultados obtenidos, el desarrollo de VITIS-IA se ha enfrentado a ciertas limitaciones inherentes a la naturaleza de los datos agrícolas y al uso de modelos estadísticos:

- **Dependencia de la Calidad del Hardware (IoT):** El modelo asume que las lecturas de los biosensores son perfectas. En la realidad, la degradación de los sensores a la intemperie puede inyectar "ruido" en los datos. El sistema actual requeriría una capa de filtrado de anomalías IoT antes de llegar a la API para evitar falsas alarmas.

- **Límites de Extrapolación Matemática:** Durante las pruebas de estrés, se comprobó que algoritmos como *Random Forest* no pueden extrapolar más allá de los datos de su conjunto de entrenamiento. Aunque esto asegura que el modelo no arroje valores negativos absurdos, lo hace dependiente de tener un *dataset* histórico muy rico que cubra todos los escenarios biológicos posibles.

- **Riesgo de Sobreajuste Local (*Local Overfitting*):** Los modelos han sido optimizados para unas variedades y un clima concreto. Trasladar VITIS-IA a otra región vitivinícola con una pluviometría drásticamente distinta requeriría metodologías de *Transfer Learning* o un reentrenamiento completo.

Mejoras y Trabajo Futuro

Habiendo completado exitosamente la integración meteorológica en tiempo real en la versión actual, la evolución natural hacia un producto comercial a gran escala requiere abordar las siguientes líneas de mejora:

- **MLOps y Reentrenamiento Continuo:** Implementar un bucle de retroalimentación (*Feedback Loop*) donde los resultados reales de cada vendimia se inyecten automáticamente en la base de datos, disparando un pipeline CI/CD que reentrene y actualice los modelos en los contenedores Docker para la siguiente temporada.

- **Integración de Visión Artificial en Rosales:** Actualmente, el estado fitosanitario se infiere de variables climáticas y de suelo. Una mejora sustancial sería entrenar Redes Neuronales Convolucionales (CNN) para analizar fotografías de las hojas de los rosales tomadas mediante cámaras en el viñedo o drones. Un enfoque multimodal (Imágenes + Sensores) aumentaría la precisión del diagnóstico temprano.

- **Interfaz Conversacional mediante LLMs:** Para salvar la brecha tecnológica con el usuario final (el agricultor), se propone integrar un Modelo de Lenguaje Grande (LLM) en la capa de presentación web. El LLM actuaría como un asesor agronómico virtual, traduciendo las salidas JSON de la API y los valores SHAP a lenguaje natural (Ejemplo: *"He detectado riesgo de estrés hídrico en la parcela sur, pero como AEMET prevé lluvias esta tarde, he bloqueado el sistema de riego automático para ahorrar costes"*).

Conclusión Final del Proyecto

El proyecto **VITIS-IA** ha demostrado con éxito el ciclo de vida completo de un producto de Inteligencia Artificial aplicada al sector *AgriTech*. Se partió de un problema empírico en la gestión de la vid, se gestionaron sesgos estadísticos en el Análisis Exploratorio, y se entrenaron ensambles predictivos interpretables mediante técnicas XAI (SHAP).

La culminación del proyecto mediante su despliegue en microservicios (Docker), la exposición de sus predicciones a través de una API REST (FastAPI) y la integración de reglas de negocio basadas en el clima real

(AEMET), hace que se acerque a una solución de software madura. El resultado es un prototipo escalable y preparado para transformar la toma de decisiones en el viñedo.